LAPORAN

DATA ANALYTICS COMPETITION FIND IT!

2024

Tim Hustler

Disusun Oleh :
Erwan Poltak Halomoan
Mohamad Maulana Firdaus Ramadhan
Viktor Arsindiantoro S

Bandung

2024

Intisari — Di tengah persaingan pasar yang ketat, industri ritel berupaya memahami perilaku pelanggan untuk meningkatkan strategi pemasaran dan promosi yang efektif. Penelitian ini bertujuan untuk mengembangkan model *machine learning* untuk memprediksi saat pelanggan akan menerima promosi, guna meningkatkan efektivitas kampanye promosi. Metode yang diaplikasikan meliputi pengolahan data menyeluruh, termasuk pra-pemrosesan, pembuatan fitur baru, dan penerapan teknik *machine learning*, dilengkapi dengan tuning hiperparameter menggunakan Optuna untuk mengoptimalkan model. Selain itu, performa model dievaluasi menggunakan *Classification Report* dan *Confusion Matrix* untuk memastikan keakuratan dalam memprediksi respons pelanggan. Hasil eksperimen menunjukkan bahwa model terbaik yaitu *Stacking Classifier* yang dilatih dengan data original dapat memprediksi penerimaan promosi dengan akurasi 79% dan skor makro masing masing *precision* 83% *recall* 79% dan f1-*score* 81%.

Kata kunci — Industri Ritel, *Machine Learning*, Stacking Classifier, Promosi, Analisis Perilaku Pelanggan, Optimalisasi Pemasaran.

I. Pendahuluan

A. Latar Belakang

Di tengah persaingan industri ritel yang semakin ketat, toko-toko dituntut untuk memahami pelanggan mereka secara mendalam untuk memperkuat strategi pemasaran dan promosi, meningkatkan layanan dan retensi pelanggan, serta menaikkan keuntungan. Menurut sebuah studi oleh Harvard Business Review, usaha yang berfokus pada data pelanggan dapat meningkatkan pengeluaran pelanggan sebesar 20-30% melalui kampanye pemasaran yang lebih terarah dan personalisasi yang efektif ("How Companies Learn Your Secrets," 2012). Ini menunjukkan pentingnya pemasaran yang tidak hanya menarik pelanggan baru tetapi juga mempertahankan pelanggan lama dengan strategi yang tepat.

Pemasaran tidak hanya berperan dalam peningkatan penjualan, tetapi juga esensial dalam memperluas pangsa pasar dan mempertahankan daya saing perusahaan. Dalam era digital ini, memahami perilaku pelanggan

melalui data mereka, seperti demografi, riwayat pembelian, dan preferensi produk, menjadi kunci utama untuk menyusun strategi pemasaran yang lebih efektif. McKinsey & Company menekankan bahwa penggunaan analitik canggih untuk data pelanggan dapat meningkatkan ROI pemasaran hingga 15-20% ("The Consumer Decision Journey," 2015).

Namun, tantangan yang dihadapi adalah pengolahan data pelanggan secara manual yang seringkali memakan waktu dan sumber daya. Dalam hal ini, teknologi pembelajaran mesin (*machine learning*) menawarkan solusi yang efisien untuk menganalisis data dalam jumlah besar dengan cepat dan akurat. Penelitian ini fokus pada penggunaan *machine learning* dalam menganalisis dataset pelanggan yang telah dikumpulkan oleh toko, yang mencakup 3.817 baris data termasuk variabel seperti kategori produk yang dibeli, frekuensi belanja, dan respons terhadap promosi.

Mengidentifikasi pola perilaku pelanggan dari data ini tidak hanya akan membantu toko dalam merumuskan pendekatan yang lebih personal dan relevan, tetapi juga dalam memperkuat loyalitas pelanggan dan meningkatkan penjualan secara keseluruhan. Dengan demikian, penelitian ini diharapkan dapat memberikan wawasan strategis yang akan memperkuat posisi toko di pasar yang kompetitif ini.

B. Tujuan

Penelitian ini memiliki tujuan sebagai berikut.

1. Membangun model untuk memprediksi pada kesempatan promosi ke berapa pelanggan akan menerima tawaran, berdasarkan data historis mereka.
2. Menggunakan model untuk menganalisis dan memahami preferensi serta perilaku pelanggan dalam merespons program promosi.
3. Memanfaatkan wawasan dari model untuk menyusun strategi promosi yang lebih tepat sasaran dan personal, sehingga meningkatkan efektivitas dan efisiensi kampanye promosi.
4. Memberikan dasar keputusan yang didukung data untuk perencanaan dan pelaksanaan program promosi masa depan.

C. Manfaat

Penelitian ini memilki manfaat sebagai berikut

1. Memungkinkan toko untuk meningkatkan efektivitas kampanye promosi dengan menyasar pelanggan yang paling mungkin merespon pada waktu yang tepat, sehingga mengoptimalkan penggunaan sumber daya pemasaran.
2. Memberikan keputusan pemasaran yang lebih baik dan didukung oleh data analitis, sehingga meningkatkan kemungkinan sukses dalam strategi pemasaran.
3. Meningkatkan pengalaman pelanggan dengan promosi yang relevan dan tepat waktu, yang diharapkan dapat meningkatkan keterlibatan pelanggan dan retensi jangka panjang.
4. Menyediakan wawasan mengenai perilaku pelanggan yang dapat dimanfaatkan untuk mengatasi persaingan di pasar.

D. Batasan Yang Digunakan

Pada penelitian ini diberikan batasan analisis yaitu penelitian ini hanya menggunakan data yang tersedia dari dataset pelanggan toko yang telah dikumpulkan, yang mencakup 3.817 baris data. Data ini mencakup variabel seperti kategori produk yang dibeli, frekuensi belanja, dan respons terhadap promosi. Data di luar set ini tidak akan dipertimbangkan dalam analisis.

E. Kontribusi Penelitian

Penelitian ini memberikan kontribusi signifikan di bidang akademik dan praktis di industri ritel dengan menerapkan model *machine learning* untuk menganalisis dan memprediksi perilaku pelanggan terkait program promosi. Hasilnya menunjukkan bagaimana teknologi canggih dapat meningkatkan keputusan pemasaran dan strategi promosi. Studi ini juga memperkaya literatur akademik dengan kasus penggunaan nyata, memberikan wawasan tentang penyesuaian promosi untuk meningkatkan efektivitasnya. Selain itu, penelitian ini membantu perusahaan ritel mengoptimalkan sumber daya, mengurangi pemborosan promosi, dan memfokuskan upaya pada inisiatif yang lebih efektif, sehingga berpotensi

mempengaruhi kebijakan dan strategi perusahaan ritel dalam jangka panjang.

II. Studi Literatur

A. *Machine Learning Classification*

Machine learning adalah cabang ilmu yang mengembangkan algoritme dan model statistik yang memungkinkan sistem komputer menjalankan tugas berdasarkan pengenalan pola dan inferensi, tanpa memerlukan instruksi eksplisit. Salah satu tugas utama *machine learning* adalah *classification*, yang termasuk dalam metode supervised learning di mana model bertujuan untuk memprediksi label yang benar dari data masukan yang diberikan (Amazon Web Services, Inc., n.d.) .

Classification mencakup berbagai jenis tugas, seperti *binary classification* yang membagi data ke dalam dua kategori eksklusif, dan *multi-class classification* yang menangani banyak kelas dan menetapkan satu kelas yang benar dari banyak pilihan. Selain itu, ada juga *multi-label classification* yang memungkinkan satu entri untuk memiliki beberapa label sekaligus, dan *imbalanced classification* yang mengatasi ketidakseimbangan jumlah sampel antar kelas yang dapat mempengaruhi performa model (Keita, 2022).

B. Model *Machine Learning Classification*

Model *Machine Learning* adalah algoritme yang dapat mengidentifikasi pola atau membuat prediksi pada kumpulan data yang belum terlihat sebelumnya. Berbeda dengan program berbasis aturan, model-model ini tidak perlu diprogram secara eksplisit dan dapat berkembang seiring waktu seiring dengan masuknya data baru ke dalam sistem (Amazon Web Services, Inc., n.d.).

Salah satu pendekatan dalam *machine learning* adalah *Ensemble Learning*, di mana beberapa model digabungkan untuk menghasilkan prediksi yang lebih akurat daripada prediksi model individual. Metode ini terbagi menjadi tiga kategori utama: *Bagging*, *Boosting*, dan *Stacking*.

*Bagging***:** Membuat beberapa model independen dan menggabungkan prediksinya untuk mengurangi varians (Brownlee, 2021).

1. Random Forest Classifier (rf)

   Random Forest adalah metode *bagging* yang membangun banyak *decision trees* pada waktu pelatihan dan mengeluarkan kelas yang merupakan mode dari kelas atau prediksi rata-rata dari pohon individual. Model ini sangat efektif untuk klasifikasi karena bisa menangani data dengan banyak fitur dan mengurangi risiko *overfitting* (Scikit-learn, n.d.).

2. Extra Trees Classifier (et)

   Mirip dengan *Random Forest*, *Extra Trees Classifier* menambahkan randomisasi ekstra dalam cara *split* digunakan, yang sering menghasilkan performa yang lebih baik pada banyak *dataset* (Scikit-learn, n.d.).

*Boosting***:** Menambah model secara berurutan, setiap model baru memperbaiki kesalahan dari model sebelumnya (Brownlee, 2021).

1. XGBClassifier (xgb)

   XGBoost adalah implementasi dari *gradient boosted decision trees* yang dirancang untuk kecepatan dan performa. *XGBoost* menyediakan algoritma yang sangat efisien untuk menyelesaikan berbagai masalah *data science* dalam waktu yang lebih cepat (Scikit-learn, n.d.).

2. CatBoost Classifier (cat)

   CatBoost adalah algoritma *machine learning* yang menggunakan *gradient boosting* pada *decision trees*. *CatBoost* unggul dalam menangani *categorical* data dan mampu mengurangi kebutuhan untuk *extensive* data *preprocessing* (CatBoost, n.d.).

3. LightGBM Classifier (lgbm)

   LightGBM adalah implementasi lain dari *gradient boosting* dengan fokus pada efisiensi dan skalabilitas, terutama pada data besar. Ini menggunakan struktur data yang berbeda dan algoritma yang lebih efisien untuk mendapatkan hasil yang lebih baik lebih cepat (LightGBM, n.d.).

4. HistGradientBoosting Classifier (hgbc)

   HistGradientBoosting Classifier adalah algoritma *boosting* berbasis histogram yang efisien untuk dataset besar dan dapat menangani nilai yang hilang secara *native* (Scikit-learn, n.d.).

*Stacking***:** Menggabungkan prediksi dari beberapa model melalui *meta-classifier* untuk membentuk model baru yang lebih kuat (Brownlee, 2021).

1. Stacking Classifier

   Stacking Classifier menggabungkan berbagai model prediksi untuk membangun model baru, biasanya melalui meta-classifier, untuk meningkatkan akurasi prediksi. *Stacking* memungkinkan pemanfaatan kekuatan prediktif dari beberapa model untuk mencapai hasil yang lebih baik (Scikit-learn, n.d.).

Pemilihan model-model ini didasarkan pada keunggulan spesifik mereka dalam berbagai aspek pengolahan data, dari kecepatan dan efisiensi hingga kemampuan dalam mengatasi data yang besar dan kompleks. Melalui kombinasi model ini, penelitian bertujuan untuk tidak hanya meningkatkan akurasi prediksi tetapi juga mengeksplorasi kemungkinan peningkatan dalam proses pembelajaran mesin untuk aplikasi industri ritel.

C. *Evaluasi Model Machine Learning Classification*

Evaluasi model adalah tahapan krusial yang menggunakan serangkaian metrik untuk mengukur kinerja model. Evaluasi ini penting untuk mengukur efektivitas model serta mengidentifikasi kelemahan utamanya (GeeksforGeeks, n.d.).

1. Confusion Matrix

   Confusion Matrix atau Matriks konfusi adalah tabel yang menggambarkan kinerja model. Tabel ini membantu mengevaluasi prediksi model dengan mengklasifikasikannya ke dalam empat kategori: positif benar, positif salah, negatif benar, dan negatif salah. Dengan masing masing definisi sebagai berikut.

- Positif Benar (TP, *True Positives*): Ini adalah kasus di mana model memprediksi hasil positif dan hasilnya benar.
- Positif Salah (FP, *False Positives*): Ini adalah kasus di mana model memprediksi hasil positif, tetapi hasilnya salah.
- Negatif Benar (TN, *True Negatives*): Ini adalah kasus di mana model memprediksi hasil negatif dan hasilnya benar.
- Negatif Salah (FN, *False Negatives*): Ini adalah kasus di mana model memprediksi hasil negatif, tetapi hasilnya salah.

2. Classification Report

Classification Report atau Laporan klasifikasi merupakan sebuah ringkasan yang menyajikan metrik penting yang diturunkan dari matriks konfusi. Laporan ini memberikan penjabaran mendetail mengenai performa model dengan menampilkan perhitungan metrik utama seperti presisi, *recall*, skor F1, serta dukungan yang diaplikasikan pada tiap kelas.

- Presisi (*Precision*): Presisi adalah jumlah positif benar dibagi dengan jumlah positif benar dan positif salah. Metrik ini mengukur keakuratan prediksi positif.
- *Recall*: *Recall* adalah jumlah positif benar dibagi dengan jumlah positif benar dan negatif salah. Metrik ini mengukur kelengkapan dari prediksi positif.
- Skor F1 (F1-*score*): Skor F1 adalah rata-rata harmonis dari presisi dan *recall*. Metrik ini menyediakan keseimbangan antara presisi dan *recall*.
- Dukungan (*Support*): Dukungan adalah jumlah sampel dalam setiap kelas.

III. Metode Eksperimen

A. Pengumpulan dan Informasi Data

Dalam upaya menyelesaikan masalah dan mencapai tujuan yang telah ditetapkan, kami telah memperoleh sebuah dataset. Dataset ini dikumpulkan oleh sebuah toko dengan tujuan untuk memahami pelanggan mereka secara lebih mendalam dan meningkatkan strategi bisnis mereka.

Dataset tersebut mencakup informasi tentang demografi pelanggan, perilaku belanja mereka, dan interaksi mereka dengan toko.

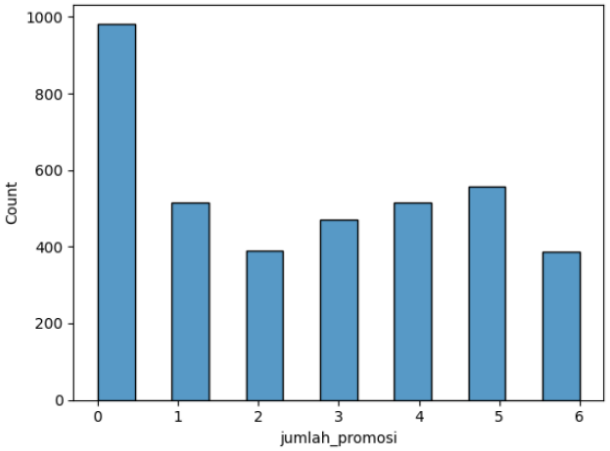
Data yang diperoleh terdiri dari 3.817 baris dan 17 kolom, termasuk kolom target, yang mencakup informasi demografi (tahun kelahiran, tingkat pendidikan, status pernikahan), data ekonomi (pendapatan), data keluarga (jumlah anak balita dan remaja), serta perilaku belanja (waktu belanja terakhir, biaya belanja per kategori, pembelian saat diskon, pembelian daring dan luring). Selain itu, terdapat data mengenai keluhan, tanggal menjadi anggota, dan partisipasi dalam program promosi. Informasi ini berguna untuk menganalisis pola pembelian berdasarkan demografi, memprediksi kemungkinan pembelian, menganalisis efektivitas program promosi, dan meningkatkan kualitas layanan pelanggan. Berikut ini merupakan tabel mengenai kolom kolom yang terdapat dalam dataset.

Tabel 1. Deskripsi Kolom dalam Dataset

Atribut	**Penjelasan**
tahun_kelahiran	Tahun kelahiran pelanggan
pendidikan	Tingkat pendidikan pelanggan (SMP,SMA,Sarjana,Magister,Doktor)
status_pernikahan	Status pernikahan pelanggan (Sendiri,Rencana Menikah,Menikah,Cerai,Cerai Mati)
pendapatan	Pendapatan pelanggan dalam rupiah
jumlah_anak_balita	Banyaknya anak pelanggan yang masih balita
jumlah_anak_remaja	Banyaknya anak pelanggan yang sudah remaja
terakhir_belanja	Jumlah hari berlalu setelah terakhir belanja
belanja_buah	Biaya yang dikeluarkan untuk belanja buah
belanja_daging	Biaya yang dikeluarkan untuk belanja daging
belanja_ikan	Biaya yang dikeluarkan untuk belanja ikan
belanja_kue	Biaya yang dikeluarkan untuk belanja kue
pembelian_diskon	Banyaknya pembelian yang dilakukan saat diskon
pembelian_web	Banyaknya pembelian yang dilakukan secara daring
pembelian_toko	Banyaknya pembelian yang dilakukan secara luring
keluhan	1 - pernah memberikan keluhan, 0 - tidak pernah
Tanggal_menjadi_anggota	Pertama kali terdaftar sebagai anggota

jumlah_promosi	(target). Pada promosi ke berapa pelanggan menerima program dari toko, dari total 6 kali promosi yang dilakukan. Nilai 0 berarti tidak menerima sama sekali

B. *Exploratory Data Analysis*

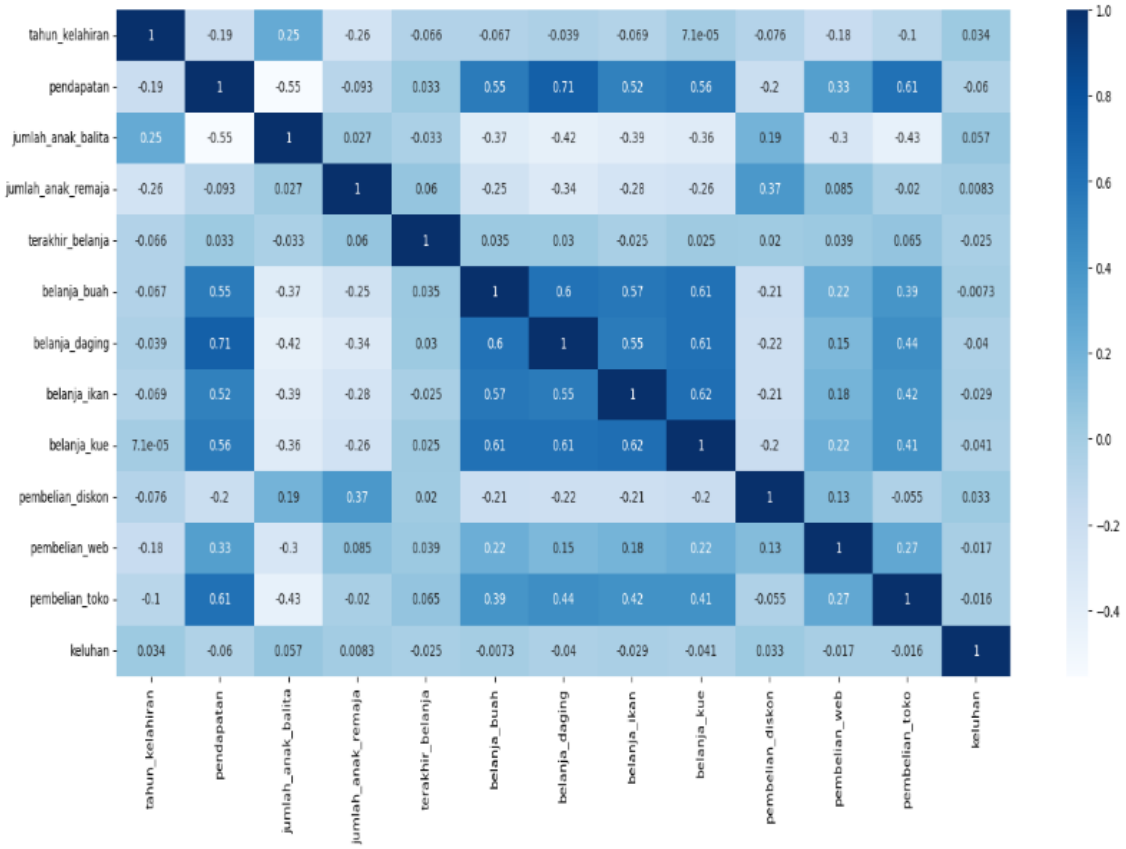


Gambar 1. Distribusi target

Gambar di atas menunjukkan distribusi *target* variabel 'jumlah_promosi', yang menggambarkan jumlah promosi yang diikuti oleh pelanggan. Dari histogram ini, dapat dilihat bahwa data target tidak seimbang (*imbalanced*).

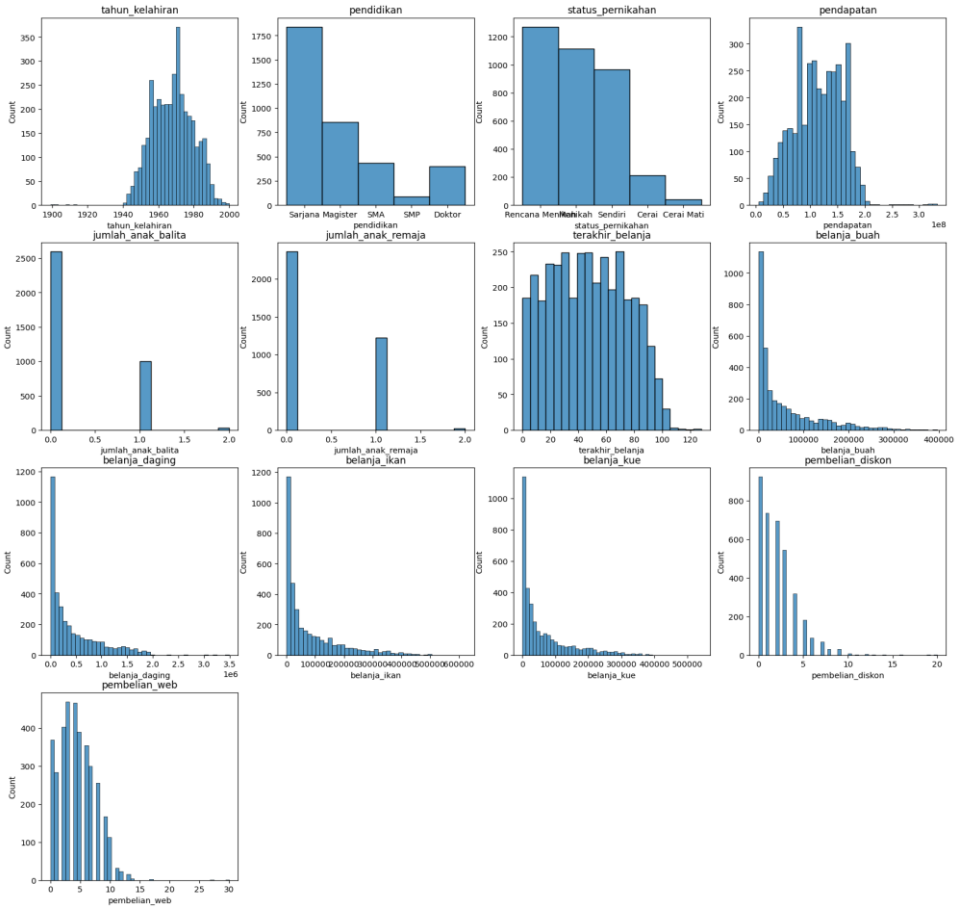
Kategori 'jumlah_promosi' 0 memiliki jumlah sampel terbesar, dengan hampir 1000 pelanggan yang tidak mengikuti satu pun promosi. Ini menunjukkan bahwa sebagian besar pelanggan cenderung tidak terlibat dalam promosi yang ditawarkan. Sementara itu, kategori 'jumlah_promosi' 1 hingga 6 menunjukkan distribusi yang lebih merata, namun dengan jumlah sampel yang jauh lebih sedikit, berkisar antara 300 hingga 600 sampel.

Selanjutnya, analisis dilakukan dengan menampilkan grafik dan korelasi untuk setiap atribut yang bertujuan untuk menemukan pola pada *dataset*. Hal ini bertujuan untuk dapat memberikan *insight* yang dapat digunakan untuk menjadi sebuah *feature creation.* Analisis ini dimulai dengan menampilkan korelasi antar atribut untuk meninjau atribut-atribut yang memberikan pengaruh signifikan.



Gambar 2. Tampilan Heatmap dataset

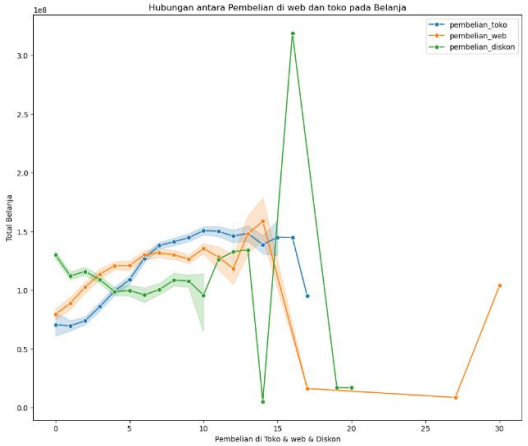
Pada tampilan *heatmap* di atas, terlihat bahwa atribut pendapatan berkorelasi positif dengan beberapa atribut belanja, seperti belanja daging, kue, ikan, dan buah. Ini mengindikasikan bahwa biaya belanja untuk setiap kategori memiliki hubungan positif dengan tingkat pendapatan. Selain itu, pendapatan juga berkorelasi positif dengan tipe pembelian, baik melalui toko maupun web, menunjukkan bahwa semakin tinggi pendapatan, semakin cenderung pelanggan melakukan pembelian secara luring di toko. Dengan demikian, kita dapat membuat fitur baru, yaitu ‘Total Spend’, yang merupakan total biaya belanja dari seluruh kategori.



Gambar 3. Tampilan Distribusi Data

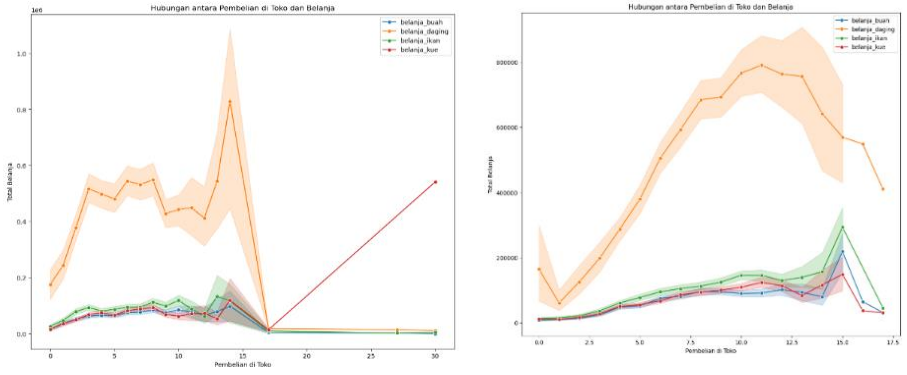
Selanjutnya, analisis dilakukan dengan persebaran distribusi dari setiap atribut, hal ini untuk meninjau demografi serta perilaku pembelanjaan yang dimiliki oleh *customer*. Pada analisis dilakukan ternyata pelanggan berkisar pada kelahiran tahun 1960-1980 yang berumur dengan kisaran acuan 2024 yaitu 44 tahun-64 tahun, yang cenderung memiliki pendidikan terakhir yaitu sarjana dan magister. Selanjutnya, untuk setiap *customer*, pendapatan yang diperoleh difokuskan pada persebaran hampir mendekati distribusi normal namun condong *skew right*, hal ini menandakan bahwa pendapatan cenderung memiliki pendapatan yang siginifikan besar. Analisis untuk perilaku pembelajaan dilakukan dengan meninjau persebaran pada grafik belanja daging,ikan, kue & buah yang ternyata sangat cenderung membentuk persebaran *skew right* yang hal ini mengindikasikan perlu dilakukan transformasi terutama jika untuk membentuk suatu *feature creation* pada dataset. Untuk meninjau lebih tinggi terkait analisis dapat

dilakukan dengan meninjau tren antara pendapatan dan jenis pembelian pelanggan yang sebelumnya didapatkan analisis bahwa hal tersebut berkorelasi positif.



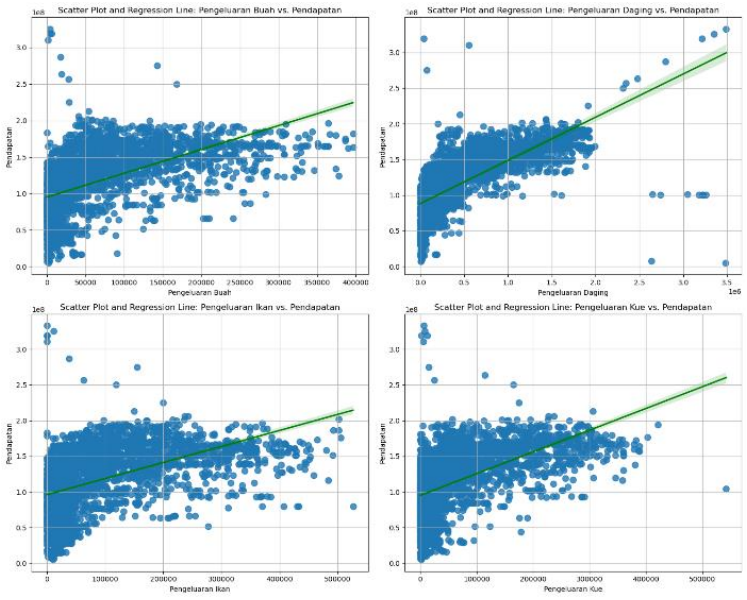
Gambar 4. hubungan antara pendapatan dan jenis pembelian

Berdasarkan analisis, terdapat korelasi positif antara pendapatan dan frekuensi pembelian langsung ke toko, yang menunjukkan bahwa individu dengan pendapatan lebih tinggi cenderung melakukan pembelian lebih sering secara langsung. Grafik menunjukkan bahwa rentang kelas pendapatan antara 15 hingga 20 menampilkan pola pembelian yang paling menonjol, memperkuat adanya korelasi positif yang kuat antara tren ini dan pendapatan. Selain itu, baik pembelian langsung ke toko maupun pembelian melalui web juga berkorelasi positif dengan pendapatan, sementara pembelian dengan diskon tidak menunjukkan tren sekuat pembelian lainnya. Hal ini mengindikasikan bahwa tidak semua pembelian dilakukan dengan diskon dan mungkin hanya terjadi pada kesempatan tertentu.



Gambar 5. Tampilan Tipe Pembelian Toko dan Belanja

Analisis tren pembelian di toko dan di web terhadap pengeluaran pelanggan pada belanja daging, ikan, buah, dan kue menunjukkan adanya korelasi positif yang signifikan. Grafik-grafik ini menunjukkan bahwa pengeluaran untuk belanja berbagai produk ini meningkat seiring dengan pendapatan, terutama dalam rentang kelas pendapatan 15-20. Tren ini memperlihatkan bahwa pembelian pada kategori tersebut cenderung meningkat secara sebanding dengan peningkatan pendapatan, menandakan bahwa pelanggan dengan pendapatan lebih tinggi cenderung mengeluarkan lebih banyak uang untuk pembelian produk-produk ini. Temuan ini dapat digunakan untuk mengidentifikasi korelasi lebih lanjut dan mengembangkan fitur atau strategi pemasaran yang lebih efektif berdasarkan analisis pendapatan dan tren pengeluaran pelanggan.



Gambar 6. Scatter Plot pendapatan dan jenis belanja

Berdasarkan analisis *scatter plot*, terlihat adanya korelasi positif antara pengeluaran belanja untuk buah, daging, ikan, dan kue dengan pendapatan. Setiap *scatter plot* menunjukkan tren positif di mana peningkatan pengeluaran untuk masing-masing kategori belanja terkait dengan peningkatan pendapatan. Persebaran data yang condong ke kanan (*skew right*) mengindikasikan bahwa sebagian besar data terkonsentrasi pada pengeluaran yang lebih rendah, tetapi terdapat beberapa kasus dengan pengeluaran yang jauh lebih tinggi.

C. *Data Preprocessing*

Pra-pemrosesan data adalah tahap awal dan krusial dalam menyiapkan data mentah agar dapat digunakan dalam model *machine learning*. Dalam mengembangkan proyek *machine learning*, seringkali data yang diperoleh belum bersih dan terorganisir dengan baik. Oleh karena itu, sangat penting untuk membersihkan dan menyusun data tersebut secara sistematis sebelum digunakan. Proses pra-pemrosesan ini tidak hanya membantu dalam memastikan data sesuai untuk model *machine learning* tetapi juga berperan dalam meningkatkan akurasi dan efisiensi dari model yang dikembangkan.

1. Penghapusan Kolom

   Berdasarkan analisis yang telah dilakukan, diketahui bahwa proporsi nilai yang tidak terisi (*null value*) pada kolom 'tanggal_menjadi_anggota' mencapai persentase yang signifikan, yaitu 72.1%. Oleh karena itu, diputuskan untuk menghapus kolom ini dari *dataset*. Keputusan ini diambil karena keberadaan jumlah besar nilai yang hilang dapat mengurangi keakuratan model dan komplikasi dalam pemrosesan data lebih lanjut.

2. Penggantian Nilai Tidak Valid

   Melalui analisis yang telah dilakukan, terungkap bahwa kolom 'status_pernikahan' dan 'pendidikan' masing-masing mengandung satu nilai yang tidak valid, yaitu angka 5. Oleh karena itu, nilai tersebut akan diubah menjadi nilai *null*. Langkah ini diambil untuk memastikan bahwa data yang digunakan dalam model *machine learning* bersih dari anomali yang dapat mengganggu analisis lebih lanjut dan mengurangi kualitas prediksi.

3. *Label Encoding*

   Untuk kolom kategorikal seperti 'status_pernikahan' dan 'pendidikan', diperlukan konversi ke bentuk numerik. Langkah ini penting agar nilai *null* yang terdapat pada kedua kolom ini dapat diisi menggunakan *Iterative Imputer*, yang tidak dapat memproses input berupa *string*. Proses *Label Encoding* ini memungkinkan setiap

kategori unik dalam kolom tersebut diwakili oleh sebuah angka, sehingga memudahkan penanganan data dan pengisian nilai yang hilang.

4. Mengisi *Null Value* Menggunakan *Iterative Imputer*

Untuk mengatasi nilai *null* dalam dataset, *Iterative Imputer* akan digunakan. Pada data numerik, *Iterative Imputer* menggunakan *Decision Tree Regressor* sebagai *base estimator*, yang efektif dalam menangani variasi data kompleks dengan membagi ruang fitur menjadi wilayah lebih kecil, dan strategi awalnya adalah 'median' untuk memberikan estimasi stabil di tengah distribusi data dengan pencilan. Untuk data kategorik, *Decision Tree Classifier* sebagai *base estimator* cocok untuk klasifikasi berdasarkan fitur kategorikal dengan memecah data berdasarkan homogenitas kelas, dan strategi awalnya adalah 'most_frequent' untuk mengisi nilai berdasarkan kategori yang paling sering muncul, meminimalkan bias terhadap kategori minoritas.

5. *One Hot Encoding*

Tahap akhir dari proses pra-pemrosesan data adalah penerapan *One Hot Encoding* pada kolom kategorikal, yaitu 'status_pernikahan' dan 'pendidikan'. Teknik ini mengubah kolom tersebut menjadi sejumlah kolom biner yang mewakili setiap kategori secara terpisah. Penerapan ini dilakukan untuk memfasilitasi model *machine learning* dalam memproses data kategorikal dengan lebih efektif, memungkinkan model untuk mengidentifikasi dan membedakan pengaruh setiap kategori secara independen tanpa mengasumsikan urutan atau hierarki di antara kategori.

D. *Feature Engineering*

Feature Engineering merupakan proses mengekstrak dan menyusun fitur-fitur penting dari data mentah agar sesuai dengan keperluan model *machine learning*. Proses ini bisa dianggap sebagai kegiatan artistik dalam menyeleksi fitur-fitur yang krusial dan mengonversinya menjadi fitur yang

lebih spesifik dan bermakna, disesuaikan untuk memenuhi kebutuhan model. *Feature Engineering* sangat vital karena dapat meningkatkan efektivitas model dengan menyajikan informasi yang lebih relevan dan efisien untuk diolah, serta membantu dalam meminimalisir kompleksitas model dengan membuang fitur-fitur yang tidak diperlukan.

1. *Feature Creation*

   Untuk memperkaya dataset dan meningkatkan prediksi model, beberapa fitur baru dikembangkan berdasarkan data yang ada. Langkah pertama adalah menghitung rasio belanja untuk buah, daging, ikan, dan kue terhadap pendapatan, yang menggambarkan proporsi pengeluaran dalam kategori tersebut. Rata-rata rasio ini kemudian dihitung untuk memahami kebiasaan konsumsi pelanggan. Fitur ‘Total_Spend’ dihitung dengan mengalikan pendapatan dengan rata-rata rasio pengeluaran, memberikan estimasi pengeluaran total yang disesuaikan dengan pendapatan.

   Selanjutnya, kolom 'pendapatan' dibagi menjadi enam kelompok (bin) menggunakan *quantile cut* untuk memfasilitasi pemodelan berbasis kategori pendapatan dan memudahkan identifikasi pola belanja pelanggan berdasarkan segmentasi pendapatan.

   Terakhir, dilakukan transformasi polinomial pada fitur Total_Spend dan 'pendapatan' dengan memangkatkan kedua variabel ini hingga pangkat dua dan tiga. Transformasi ini bertujuan untuk menangkap relasi non-linear antara pengeluaran dan pendapatan, serta meningkatkan sensitivitas model terhadap perubahan kecil dalam data masukan.

2. *Feature Droping*

   Selanjutnya, setelah menggunakan fitur keluhan untuk melakukan imputasi, terungkap bahwa fitur ini memiliki ketidakseimbangan data yang sangat tinggi dan memiliki korelasi yang rendah terhadap kolom kolom yang ada. Berdasarkan hal tersebut, diputuskan untuk menghapus fitur keluhan dari dataset.

Keputusan ini diambil untuk memastikan efisiensi model machine learning dan menghindari distorsi yang mungkin ditimbulkan oleh variabel yang kurang informatif.

3. *Feature Encoding*

Setelah pembuatan fitur baru 'pendapatan_qcut' dalam tahap pembuatan fitur, fitur ini akan diterapkan dengan metode *one hot encoding*. Penerapan teknik ini bertujuan untuk mengubah kategorisasi pendapatan yang telah dibagi menjadi beberapa kelompok menjadi serangkaian kolom biner. Langkah ini dilakukan untuk memastikan bahwa model *machine learning* dapat memproses data kategorikal ini tanpa mengasumsikan adanya urutan atau hierarki antar kelompok, sehingga dapat meningkatkan keakuratan prediksi model dengan memperlakukan setiap kategori pendapatan sebagai entitas yang terpisah dan independen.

4. *Feature Transformation*

Selain itu, beberapa fitur numerik seperti Total_Spend, belanja_buah, belanja_ikan, belanja_daging, belanja_kue, dan pendapatan ditransformasi menggunakan fungsi log1p. Langkah ini diambil karena fitur-fitur tersebut memiliki distribusi yang condong ke kanan (*right-skewed*), sehingga penggunaan log1p bertujuan untuk menormalkan distribusi dan mengurangi pengaruh nilai ekstrem. Transformasi log1p juga dipilih karena kemampuannya untuk menangani nilai nol yang ada dalam data, mengonversi nilai tersebut menjadi nol dalam skala logaritmik tanpa kesalahan penghitungan. Transformasi ini penting untuk meningkatkan stabilitas numerik dan kinerja model.

5. *Feature Scaling*

Sebagai tahapan akhir dalam proses *feature engineering*, fitur-fitur numerik seperti belanja_buah, belanja_daging, belanja_ikan, belanja_kue, pendapatan, Total_Spend, pendapatan_2, Total_Spend_2, Total_Spend_3, dan pendapatan_3 di-scaled menggunakan Robust Scaler. Robust Scaler dipilih karena

ketahanannya terhadap *outlier*, mengurangi risiko distorsi pada distribusi fitur yang disebabkan oleh nilai-nilai ekstrem. *Scaling* ini penting untuk memastikan semua fitur numerik memiliki skala yang seragam, memudahkan algoritme *machine learning* dalam proses pembelajaran, meningkatkan efisiensi komputasi, dan memastikan setiap fitur memiliki pengaruh yang setara dalam model prediktif..

E. *Model Development*

Setelah dataset diproses dan siap untuk digunakan, langkah berikutnya adalah pelatihan algoritma machine learning yang telah dipilih sebelumnya menggunakan data yang sudah siap. Pertama-tama, data dibagi dengan proporsi 80:20, di mana 80% data digunakan sebagai data pelatihan dan 20% sebagai data validasi. Proses pembagian data ini bertujuan untuk memastikan bahwa model dapat dilatih dengan data yang cukup dan divalidasi secara efektif untuk menghindari overfitting. Kolom-kolom akhir yang digunakan dalam model meliputi: tahun_kelahiran, pendapatan, jumlah_anak_balita, jumlah_anak_remaja, terakhir_belanja, belanja_buah, belanja_daging, belanja_ikan, belanja_kue, pembelian_diskon, pembelian_web, pembelian_toko, Total_Spend2, Total_Spend2_2, Total_Spend2_3, pendapatan_2, pendapatan_3, serta kolom hasil one-hot encoding untuk status_pernikahan (0.0 hingga 4.0), pendapatan_qcut (0 hingga 5), dan pendidikan (0.0 hingga 4.0).

Beberapa model yang digunakan meliputi Random Forest Classifier, XGBClassifier, CatBoost Classifier, LightGBM Classifier, Extra Trees Classifier, HistGradientBoosting Classifier, dan Stacking Classifier. Dari model-model ini, XGBClassifier, CatBoost Classifier, LightGBM Classifier, dan HistGradientBoosting Classifier menjalani proses penyetelan hiperparameter menggunakan Optuna untuk mengoptimalkan setiap model berdasarkan data yang tersedia. Model-model lain seperti Random Forest Classifier, Logistic Regression, dan Extra Trees Classifier diimplementasikan dengan parameter standar untuk mengevaluasi dan membandingkan performa mereka dalam prediksi yang independen.

Setelah itu, model-model yang telah dioptimalkan akan diintegrasikan ke dalam stacking classifier sebagai *base estimator*, dengan *Logistic Regression* digunakan sebagai *final estimator*. Penggunaan *stacking classifier* bertujuan untuk menggabungkan kekuatan prediktif dari berbagai model yang telah dioptimalkan, menghasilkan prediksi yang lebih akurat dan *robust* dengan memanfaatkan kelebihan dari masing-masing model yang terlibat.

F. *Rancangan Eksperimen*

Untuk mengatasi ketidakseimbangan data dalam dataset, empat eksperimen dilakukan sebagai berikut:

1. Menggunakan Data Tanpa Modifikasi (Original): Data digunakan sebagaimana adanya tanpa melakukan penyesuaian untuk menangani ketidakseimbangan kelas.
2. Menerapkan Class Weight (CW): Class weight digunakan untuk menyesuaikan ketidakseimbangan kelas dengan memberi bobot lebih besar pada kelas minoritas.
3. Menggunakan SMOTE (Synthetic Minority Over-sampling Technique): SMOTE digunakan untuk menghasilkan sampel sintetis dari kelas minoritas, menambah jumlah sampel pada kelas tersebut.
4. Menggunakan Random Under Sampling (RUS): Teknik ini digunakan untuk mengurangi jumlah sampel pada kelas mayoritas agar seimbang dengan kelas minoritas.

IV. Hasil dan Analisis Eksperimen

A. *Hasil*

Dari eksperimen yang telah dilakukan, hasil yang diperoleh dari Classification Report untuk berbagai model yang dilatih disajikan dalam tabel berikut, menunjukkan skor F1 untuk masing-masing model dalam berbagai eksperimen.

Tabel 2. Hasil f1-*score* model

Model	Original	CW	SMOTE	RUS
Random Forest	0. 78072	0. 78568	0. 75557	0. 72432
XGBoost	0. 73254	0. 73254	0. 68860	0. 67425

CatBoost	0. 75722	0. 76008	0. 75806	0. 72192
LightBGM	0. 77071	0. 74372	0. 74225	0. 71169
Extra Tree	0. 78511	0. 77674	0. 74020	0. 72832
High Gradient Boosting	0. 76437	Tidak Ada	0. 74471	0. 70737
Stacking Classifier	0. 806599	Tidak Ada	0. 76929	0. 75748

Dari eksperimen yang telah dilakukan, hasil yang diperoleh dari Classification Report untuk berbagai model yang dilatih disajikan dalam tabel berikut, menunjukkan skor F1 untuk masing-masing model dalam berbagai eksperimen. Tabel tersebut menunjukkan bahwa *Stacking Classifier* memiliki performa terbaik pada data asli dengan skor F1 sebesar 0.806599.

B. *Analisis*

Dari tabel hasil f1-*score* model, Penerapan *class weight* menunjukkan hasil yang bervariasi. Model seperti Random Forest dan CatBoost sedikit meningkat dalam f1-*score* saat menggunakan *class weight* (CW), tetapi tidak signifikan. Ini mungkin disebabkan oleh ketidakmampuan model untuk memberikan bobot yang tepat kepada kelas minoritas atau karena bobot yang diterapkan tidak cukup untuk menangani ketidakseimbangan yang ekstrim antara kelas 0 dan kelas lainnya.

Penerapan SMOTE (Synthetic Minority Over-sampling Technique) juga memberikan hasil yang tidak memuaskan. Pembuatan data sintetis tampaknya tidak berhasil meningkatkan performa model secara keseluruhan dan bahkan menyebabkan penurunan f1-*score* pada beberapa model, seperti XGBoost dan CatBoost. Data sintetis yang dibuat mungkin tidak cukup baik untuk merepresentasikan karakteristik kelas minoritas yang sebenarnya, yang menyebabkan model mengalami *bias* dan *variance* yang lebih tinggi. Hal ini mengindikasikan bahwa SMOTE mungkin memperkenalkan *noise* ke dalam data, yang membuat model kesulitan dalam membedakan antara kelas.

Terakhir, Random Under Sampling (RUS) juga menunjukkan penurunan f1-*score* pada hampir semua model. Teknik ini menghapus sebagian data dari kelas mayoritas untuk menyeimbangkan data, tetapi ini

mungkin menyebabkan penghapusan data penting yang membawa ciri khas dari kelas tersebut. Akibatnya, model kehilangan informasi penting yang diperlukan untuk membuat prediksi yang akurat, yang akhirnya menurunkan performa model. Hal ini menunjukkan bahwa RUS dapat mengakibatkan hilangnya informasi yang berharga dan tidak selalu merupakan solusi yang efektif untuk menangani ketidakseimbangan data.

Dalam eksperimen ini, *Stacking Classifier* terpilih sebagai model dengan performa terbaik berdasarkan hasil-hasil yang terukur dalam f1-*score classification report*. Selanjutnya akan dilakukan analisis terhadap hasil yang telah diperoleh sebelumnya. Analisis ini bertujuan untuk mendalami lebih lanjut tentang bagaimana model ini bekerja dan memberikan wawasan tentang area yang bisa ditingkatkan.

Stacking Classifier

	precision	recall	f1-score	support
0	0.67	0.82	0.74	195
1	0.64	0.56	0.60	120
2	0.85	0.70	0.76	79
3	0.89	0.83	0.86	84
4	0.93	0.98	0.95	91
5	0.93	0.93	0.93	120
6	0.90	0.73	0.81	75
accuracy			0.79	764
macro avg	0.83	0.79	0.81	764
weighted avg	0.80	0.79	0.79	764

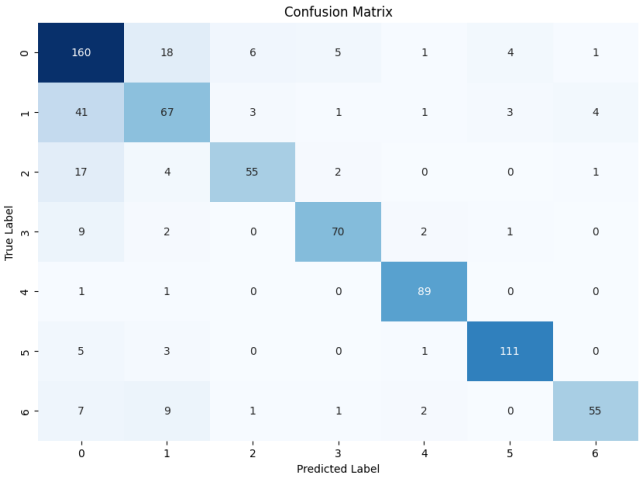
Gambar 7. Hasil Classification Report model

Hasil *classification report* dari *Stacking Classifier* menunjukkan performa model dalam melakukan klasifikasi pada beberapa kelas yang berbeda. Dari tabel tersebut, dapat dilihat bahwa model memiliki tingkat *precision*, *recall*, dan *f1-score* yang bervariasi untuk setiap kelas. Sebagai contoh, untuk kelas 0, *precision* mencapai 0.67, *recall* 0.82, dan *f1-score* 0.74 dengan dukungan data sebanyak 195. Di sisi lain, kelas 4 memiliki nilai *precision*, *recall*, dan *f1-score* yang lebih tinggi, masing-masing sebesar 0.93, 0.98, dan 0.95 dengan dukungan data sebanyak 91. Nilai-nilai ini menunjukkan bahwa model lebih efektif dalam mengklasifikasikan beberapa kelas tertentu dibandingkan kelas lainnya.

Skor rata - rata *macro precision*, *recall*, dan f1-*score* adalah masing-masing 0.83, 0.79, dan 0.81, yang menghitung rata-rata setiap skor *metric*

tanpa mempertimbangkan jumlah data dalam setiap kelas, sehingga setiap kelas dianggap sama pentingnya. *Weighted average* memperhitungkan jumlah data dalam setiap kelas, menghasilkan *precision*, *recall*, dan f1-*score* masing-masing 0.80, 0.79, dan 0.79, menunjukkan bahwa model ini cukup baik dalam mengklasifikasikan data dengan distribusi yang tidak merata. Akurasi model keseluruhan adalah 0.79, yang berarti sekitar 79% dari semua prediksi model adalah benar. Perbedaan antara macro average dan weighted average memberikan wawasan tentang performa model dalam mengklasifikasikan data yang tidak seimbang, dengan tingginya skor recall pada kelas 4 dan 5 menunjukkan kemampuan model mengenali data dalam kelas tersebut, meskipun masih perlu peningkatan untuk kelas dengan skor recall lebih rendah seperti kelas 1 dan 2.

Setelah membahas *classification report* dari *Stacking Classifier*, langkah berikutnya adalah menganalisis confusion matrix untuk mendapatkan gambaran yang lebih detail mengenai performa model dalam mengklasifikasikan data ke dalam kelas yang benar. *Confusion matrix* memberikan informasi tentang prediksi yang benar dan yang dilakukan oleh model, yang sangat berguna untuk memahami di mana model sering melakukan kesalahan.



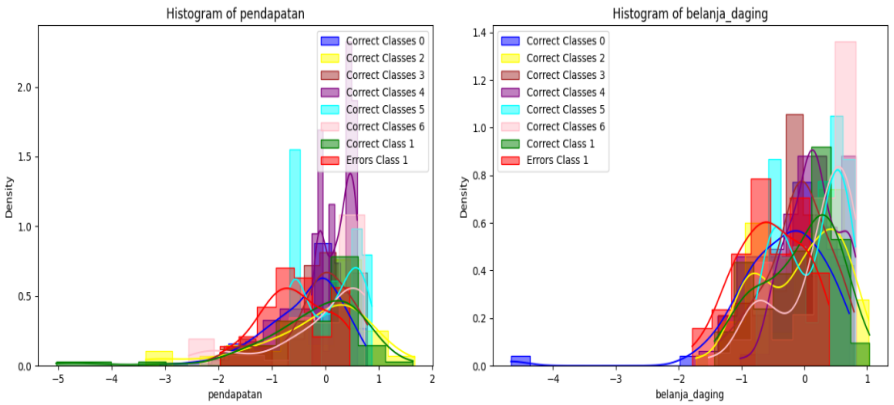
Gambar 8. Hasil Confussion Matrix model

Dari *confusion matrix* tersebut, dapat dilihat bahwa model memiliki performa yang cukup baik pada beberapa kelas, tetapi kurang baik pada

yang lain. Sebagai contoh, untuk kelas 0, model berhasil mengklasifikasikan 160 sampel dengan benar, tetapi masih terdapat kesalahan prediksi sebanyak 35 sampel yang tersebar ke berbagai kelas lainnya. Kelas 4 dan kelas 5 menunjukkan performa yang sangat baik dengan 89 dan 111 prediksi yang benar dari total data, masing-masing hanya mengalami sedikit kesalahan. Kelas 6 juga menunjukkan hasil yang cukup baik dengan 55 prediksi benar, meskipun terdapat beberapa kesalahan.

Namun, terdapat beberapa kelas seperti kelas 1 dan kelas 2 di mana model melakukan banyak kesalahan prediksi. Untuk kelas 1, hanya 67 sampel yang diklasifikasikan dengan benar, sedangkan 53 sampel lainnya salah diklasifikasikan ke kelas lain. Demikian pula untuk kelas 2, terdapat 55 prediksi benar dari total sampel, tetapi cukup banyak sampel yang salah prediksi. Kesalahan prediksi ini bisa disebabkan oleh kemiripan fitur antara beberapa kelas yang menyebabkan model kesulitan untuk membedakan antara mereka. Selain itu, distribusi data yang tidak merata juga dapat mempengaruhi performa model, terutama pada kelas dengan jumlah sampel yang lebih sedikit, yang menyebabkan model kurang terlatih pada kelas tersebut.

Setelah membahas hasil dari *confusion matrix*, langkah selanjutnya adalah menganalisis *feature importance* untuk memahami kontribusi masing-masing fitur terhadap prediksi model. *Feature importance* menunjukkan seberapa penting setiap fitur dalam membantu model membuat prediksi yang akurat, yang penting untuk mengidentifikasi fitur-fitur kunci dan meningkatkan performa model



Gambar 9. Distribusi kolom pendapatan dan belanja_daging

Grafik di atas menunjukkan histogram dan plot KDE untuk kedua fitur ini, dengan memisahkan kelas yang benar terprediksi dan kelas yang salah prediksi. Pada fitur 'pendapatan', terlihat bahwa distribusi KDE untuk kelas error (Class 1 yang salah diprediksi sebagai Class 0) sangat dekat dengan distribusi KDE untuk Class 0. Hal ini menyebabkan model mengalami bias dan sering salah prediksi antara Class 1 dan Class 0. Demikian juga pada fitur 'belanja_daging', distribusi KDE untuk error class juga menunjukkan pola yang mirip dengan beberapa kelas lainnya, yang menyebabkan kesalahan prediksi. Selanjutnya akan mengecek *feature importance* untuk mengetahui bagaimana fitur - fitur mempengaruhi kinerja model.

	RandomForest	XGBoost	CatBoost	LightGBM	ExtraTrees
pendapatan	0,062974	0,054539	4,164282	8644	0,059211
belanja_buah	0,057758	0,029256	7,720015	5074	0,045827
belanja_daging	0,077211	0,040172	6,660338	5410	0,056934
belanja_ikan	0,063142	0,030568	7,47132	5177	0,04611
belanja_kue	0,058632	0,025974	7,543172	4835	0,044536
Total_Spend2	0,062133	0	0,832921	579	0,056814
Total_Spend2_2	0,065609	0	0,858672	29	0,05656
Total_Spend2_3	0,063374	0	0,79747	0	0,056038
pendapatan_2	0,063092	0	0,951181	0	0,056209
pendapatan_3	0,061246	0	0,885281	0	0,056739
jumlah_anak_balita	0,009831	0,05796	1,631477	414	0,018692
jumlah_anak_remaja	0,014016	0,06483	2,864875	422	0,024514

Gambar 10. Hasil Sebagian Feature Importance model

Dari tabel *feature importance* yang diberikan, terlihat bahwa fitur 'pendapatan' dan 'belanja_daging' memiliki nilai *importance* yang tinggi di beberapa model, seperti CatBoost dan LightGBM. Ini menunjukkan bahwa kedua fitur tersebut memainkan peran penting dalam prediksi model dan memberikan kontribusi yang signifikan terhadap kinerja model. 'Pendapatan' memiliki importance yang tinggi terutama pada CatBoost dan LightGBM, mengindikasikan bahwa informasi ekonomi pelanggan adalah faktor utama dalam menentukan partisipasi dalam promosi. Demikian pula, 'belanja_daging' menunjukkan *importance* yang tinggi pada beberapa model, menunjukkan bahwa perilaku belanja dalam kategori ini juga sangat berpengaruh. Sebaliknya, fitur seperti 'jumlah_anak_balita' dan 'jumlah_anak_remaja' memiliki nilai *importance* yang rendah di hampir semua model, yang menunjukkan bahwa fitur-fitur ini kurang berpengaruh terhadap prediksi model dan mungkin tidak relevan dalam konteks ini.

Perbedaan nilai *importance* seperti yang terlihat pada fitur 'Total_Spend2_2', yang memiliki nilai tinggi pada Random Forest (RF) dan Extra Trees (ET) tetapi rendah pada model lainnya, menunjukkan perbedaan dalam cara kerja model. Random Forest dan Extra Trees mengandalkan pembentukan banyak pohon keputusan independen, yang mungkin memberikan bobot lebih besar pada fitur tertentu berdasarkan bagaimana mereka membagi data secara acak. Sementara itu, model seperti CatBoost dan LightGBM yang menggunakan *boosting*, mungkin kurang sensitif terhadap fitur ini karena pendekatan bertahap mereka yang fokus pada memperbaiki kesalahan dari model sebelumnya.

Berdasarkan analisis yang telah dilakukan, beberapa langkah perbaikan di masa depan dapat diambil untuk meningkatkan performa model. Pertama, melakukan feature engineering untuk menambah fitur baru yang dapat membedakan setiap kelas, terutama antara kelas 0 dan 1, akan sangat membantu. Menambahkan jumlah data dengan pengumpulan data baru dapat membantu model dalam belajar dari lebih banyak contoh dan meningkatkan generalisasi.

V. Kesimpulan

Dari eksperimen yang telah dilakukan, dapat disimpulkan bahwa model *Stacking Classifier* tanpa melakukan penanganan *imbalanced* data menunjukkan performa yang cukup baik dengan skor akurasi 0.79, serta *macro average precision*, *recall*, dan f1-*score* masing-masing sebesar 0.83, 0.79, dan 0.81. Analisis *confusion matrix* menunjukkan bahwa model memiliki performa yang baik pada beberapa kelas, seperti kelas 4 dan 5, namun masih mengalami kesalahan prediksi yang cukup banyak pada kelas-kelas lain seperti kelas 1 dan 2. Ada beberapa langkah perbaikan yang dapat diambil untuk meningkatkan performa model di masa depan. Pertama, melakukan rekayasa fitur atau melakukan pengumpulan data fitur baru untuk menambah fitur yang dapat membedakan setiap kelas, terutama antara kelas 0 dan 1. Menambah jumlah data dengan pengumpulan data baru juga dapat membantu model belajar dari lebih banyak contoh dan meningkatkan kemampuan generalisasi.

Daftar Pustaka

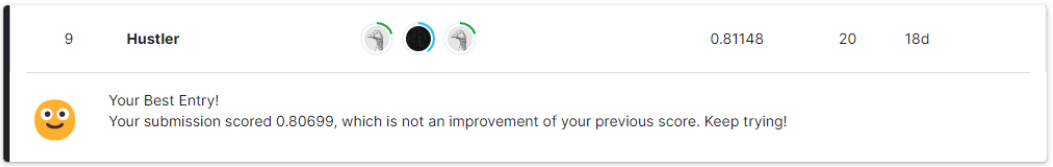
- Abdullah, S., (n.d.). Confusion matrices and classification reports: A guide to evaluating machine learning models. Available at: https://smuhabdullah.medium.com/confusion-matrices-and-classification-reports-a-guide-to-evaluating-machine-learning-models-385496cf7cee [Accessed on: 11 May 2024].
- Amazon Web Services, Inc. (n.d.). Apa itu Machine Learning? - Panduan Pemula Machine Learning Korporasi - AWS. Available at: https://aws.amazon.com/id/what-is/machine-learning/ [Accessed on: 11 May 2024].
- Analytics Vidhya. (2021). A Beginner's Guide to Feature Engineering: Everything You Need to Know. Available at: https://www.analyticsvidhya.com/blog/2021/10/a-beginners-guide-to-feature-engineering-everything-you-need-to-know/ [Accessed on: 11 May 2024].
- Brownlee, J. (2021). A Gentle Introduction to Ensemble Learning Algorithms. [online] Machine Learning Mastery. Available at: https://machinelearningmastery.com/tour-of-ensemble-learning-algorithms/ [Accessed on: 19 May 2024].
- Chen, T. and Guestrin, C., 2016. XGBoost: A Scalable Tree Boosting System. Available at: https://xgboost.readthedocs.io/en/latest/ [Accessed on: 11 May 2024].
- Court, D., Elzinga, D., Mulder, S., & Vetvik, O. J. (2015). The Consumer Decision Journey. McKinsey & Company. Available at: https://www.mckinsey.com/business-functions/marketing-and-sales/our-insights/the-consumer-decision-journey [Accessed on: 11 May 2024].
- Duhigg, C. (2012). How Companies Learn Your Secrets. The New York Times. Available at: https://www.nytimes.com/2012/02/19/magazine/shopping-habits.html [Accessed on: 11 May 2024].
- GeeksforGeeks. (n.d.). Machine Learning: Model Evaluation. Available at: https://www.geeksforgeeks.org/machine-learning-model-evaluation/ [Accessed on: 11 May 2024].
- JavaTpoint. (n.d.). Data Preprocessing in Machine Learning. Available at: https://www.javatpoint.com/data-preprocessing-machine-learning [Accessed on:

11 May 2024].

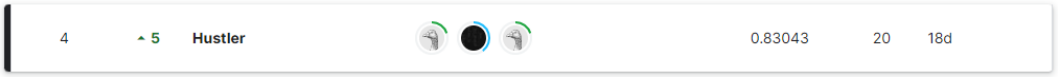
- Keita, Z. (2022). Classification in Machine Learning: A Guide for Beginners. Available at: https://www.datacamp.com/blog/classification-machine-learning [Accessed on: 11 May 2024].
- Microsoft. (n.d.). LightGBM. Available at: https://lightgbm.readthedocs.io/en/latest/ [Accessed on: 11 May 2024].
- Prokhorenkova, L., et al., 2017. CatBoost: unbiased boosting with categorical features. Available at: https://catboost.ai/docs/concepts/about.html [Accessed on: 11 May 2024].
- scikit-learn. (n.d.). ExtraTreesClassifier. Available at: https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.ExtraTreesClassifier.html [Accessed on: 11 May 2024].
- scikit-learn. (n.d.). HistGradientBoostingClassifier. Available at: https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.HistGradientBoostingClassifier.html [Accessed on: 11 May 2024].
- scikit-learn. (n.d.). RandomForestClassifier. Available at: https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html [Accessed on: 11 May 2024].
- scikit-learn. (n.d.). StackingClassifier. Available at: https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.StackingClassifier.html [Accessed on: 11 May 2024].
- Towards Data Science. (n.d.). Modeling: Teaching a Machine Learning Algorithm to Deliver Business Value. Available at: https://towardsdatascience.com/modeling-teaching-a-machine-learning-algorithm-to-deliver-business-value-ad0205ca4c86 [Accessed on: 11 May 2024].

Lampiran

Skor Public Leaderboard



Skor Private Leaderboard



Informasi Dataset

```
RangeIndex: 3817 entries, 0 to 3816
Data columns (total 17 columns):
 #   Column                  Non-Null Count  Dtype
---  ------                  --------------  -----
 0   tahun_kelahiran         3817 non-null   int64
 1   pendidikan              3628 non-null   object
 2   status_pernikahan       3605 non-null   object
 3   pendapatan              3627 non-null   float64
 4   jumlah_anak_balita      3627 non-null   float64
 5   jumlah_anak_remaja      3613 non-null   float64
 6   terakhir_belanja        3645 non-null   float64
 7   belanja_buah            3636 non-null   float64
 8   belanja_daging          3639 non-null   float64
 9   belanja_ikan            3624 non-null   float64
 10  belanja_kue             3603 non-null   float64
 11  pembelian_diskon        3639 non-null   float64
 12  pembelian_web           3652 non-null   float64
 13  pembelian_toko          3648 non-null   float64
 14  keluhan                 3621 non-null   float64
 15  tanggal_menjadi_anggota 1065 non-null   object
 16  jumlah_promosi          3817 non-null   int64
dtypes: float64(12), int64(2), object(3)
```

Baris ke-1 hingga ke-5 dan kolom ke-1 hingga ke-5 data

	tahun_kelahiran	pendidikan	status_pernikahan	pendapatan	jumlah_anak_balita	jumlah_anak_remaja	terakhir_belanja
0	1979	Sarjana	Rencana Menikah	NaN	0.0	1.0	NaN
1	1950	Sarjana	Rencana Menikah	84063000.0	NaN	NaN	70.0
2	1966	Sarjana	Menikah	127532564.0	0.0	0.0	45.0
3	1961	Magister	Rencana Menikah	165579620.0	0.0	0.0	90.0
4	1970	Sarjana	Rencana Menikah	117703159.0	1.0	1.0	78.0

Baris ke-1 hingga ke-5 dan kolom ke-8 hingga ke-15 data

belanja_buah	belanja_daging	belanja_ikan	belanja_kue	pembelian_diskon	pembelian_web	pembelian_toko	keluhan
50575.0	260967.0	50575.0	20230.0	2.0	2.0	5.0	0.0
6069.0	44506.0	80920.0	20230.0	9.0	6.0	4.0	0.0
117611.0	265460.0	96341.0	145573.0	1.0	1.0	7.0	0.0
206346.0	1613901.0	27725.0	125868.0	0.0	7.0	8.0	0.0
90563.0	311757.0	40358.0	33875.0	7.0	6.0	5.0	0.0

Baris ke-1 hingga ke-5 dan kolom ke-16 hingga ke-17 data

tanggal_menjadi_anggota	jumlah_promosi
2014-05-05	2
2013-03-17	0
NaN	1
NaN	4
NaN	4

Pengecekan nilai unik dari kolom kategorikal

```
    # check unique value on object columns
    for i in train.columns:
      if train[i].dtypes == 'object':
        print(f'{i}: {train[i].unique()}')
```

```
pendidikan: ['Sarjana' 'Magister' 'SMA' 'SMP' 'Doktor' nan '5']
status_pernikahan: ['Rencana Menikah' 'Menikah' 'Sendiri' 'Cerai' nan 'Cerai Mati' '5']
```

Pengecekan jumlah persentase data null

```
    for i in train.columns:
      print(f'{i}: {train[i].isna().sum()/len(train)*100}%')
```

```
tahun_kelahiran: 0.0%
pendidikan: 4.951532617238669%
status_pernikahan: 5.554100078595756%
pendapatan: 4.977731202515065%
jumlah_anak_balita: 4.977731202515065%
jumlah_anak_remaja: 5.344511396384595%
terakhir_belanja: 4.506156667539953%
belanja_buah: 4.741943935027509%
belanja_daging: 4.663348179198323%
belanja_ikan: 5.05632695834425%
belanja_kue: 5.606497249148546%
pembelian_diskon: 4.663348179198323%
pembelian_web: 4.322766570605188%
pembelian_toko: 4.427560911710768%
keluhan: 5.134922714173435%
tanggal_menjadi_anggota: 72.09850668063925%
jumlah_promosi: 0.0%
```